Sprint 1

Grupo 03
Alejandro De Haro, Juan Díaz & Daniel Escobosa

Tecnologías de Procesamiento Big Data
3º Grado en Ingeniería Matemática e Inteligencia Artificial

Índice

Tabla de contenido

Introducción *3*

Metodología *4*

Conclusión *7*

Introducción

Contexto

Este proyecto se desarrolla en el contexto de la creación de un nuevo departamento dentro de un gran banco, orientado al asesoramiento a clientes en el ámbito del trading de criptomonedas, un mercado caracterizado por su elevada volatilidad y por la necesidad de realizar análisis intensivos sobre grandes volúmenes de datos históricos y en tiempo real.
En este marco, el proyecto plantea el diseño de una arquitectura Big Data sobre Amazon Web Services (AWS) que permita almacenar, procesar y analizar información de mercado de manera eficiente, escalable y fiable. Este primer sprint constituye la primera fase del proyecto y se centra en la definición e implementación de la capa de almacenamiento de datos históricos, que servirá como base para los análisis posteriores y para el desarrollo de futuros casos de uso como la identificación de tendencias, la monitorización en tiempo real y la generación de informes.

Descripción del problema y objetivos del sprint

Antes de empezar con las tareas de análisis avanzado o procesamiento en streaming, es importante garantizar que los datos históricos se encuentran correctamente ingestados, organizados y validados.
El problema a resolver en este sprint consiste, por tanto, en sentar las bases de un data lake inicial que permita almacenar de forma estructurada los datos históricos de mercado de una criptomoneda.
El objetivo principal del Sprint 1 es definir y poner en funcionamiento la primera capa de almacenamiento de datos históricos en Amazon S3, utilizando como caso de estudio la criptomoneda Avalanche (AVAX). Para ello, se plantean los siguientes objetivos específicos:

- Obtener los datos históricos diarios de Avalanche desde TradingView, utilizando el exchange Binance.
- Realizar un análisis exploratorio inicial que permita evaluar la calidad, continuidad y coherencia temporal de los datos.
- Diseñar una estructura de almacenamiento escalable y genérica en Amazon S3.
- Automatizar la creación del bucket y la carga de los datos históricos en formato CSV, organizados por año y mes.

Metodología

Comprobación inicial de los datos

El cuaderno analisisDatos.ipynb se ejecutó inicialmente como paso de verificación para comprobar que los datos importados en la capa de almacenamiento eran correctos y completos. En él se documenta el proceso de validación y análisis exploratorio, que incluye la normalización de los nombres de las columnas, la conversión de tipos de datos, la ordenación temporal de los registros y la aplicación de controles de calidad sobre valores nulos, duplicados y cobertura de los rangos temporales. Esta ejecución inicial permitió confirmar que no existían datos faltantes relevantes ni inconsistencias críticas, aportando confianza sobre la calidad del histórico almacenado. De este modo, la combinación de scripts y notebooks no solo implementa la solución técnica, sino que también justifica las decisiones adoptadas y demuestra que el sistema está preparado para crecer y adaptarse a nuevos activos o fuentes de datos sin necesidad de rediseños profundos.

Ilustración 1. Gráfica de la evolución del valor de la criptomoneda AVALANCHE (AVAX)

Entorno de desarrollo y ejecución

La metodología seguida en este sprint se ha centrado en definir y poner en marcha la primera capa de almacenamiento de datos históricos del proyecto, alineándose con la arquitectura Big Data propuesta sobre AWS. En primer lugar, se estableció el entorno de desarrollo utilizando Python como lenguaje principal, apoyándose en librerías estándar para análisis de datos (pandas, numpy, matplotlib) y en el SDK oficial de AWS (boto3) para la interacción con Amazon S3.

El diseño de la solución parte de una decisión clave: organizar la información histórica de forma escalable y genérica, siguiendo buenas prácticas de data lake. Para ello, se implementó el script crearBucket.py, cuyo propósito es automatizar todo el ciclo de vida inicial del almacenamiento: verificación y eliminación previa del bucket (para asegurar idempotencia en entornos de prueba), creación del bucket en la región definida y carga estructurada de los datos históricos. Los datos se obtienen desde TradingView mediante una librería específica, extrayendo series temporales diarias del par AVAX/USD desde Binance, con un volumen suficiente de barras históricas para cubrir los 4 años anteriores desde la fecha actual.

Posteriormente, los datos se enriquecen con atributos temporales (año y mes) que permiten particionar la información de forma lógica. Esta partición se refleja tanto en el nombre de los ficheros CSV generados como en la jerarquía de carpetas dentro de S3 (crypto=avalanche, year=YYYY, month=MM), lo que facilita futuros procesos batch con herramientas como AWS Glue.

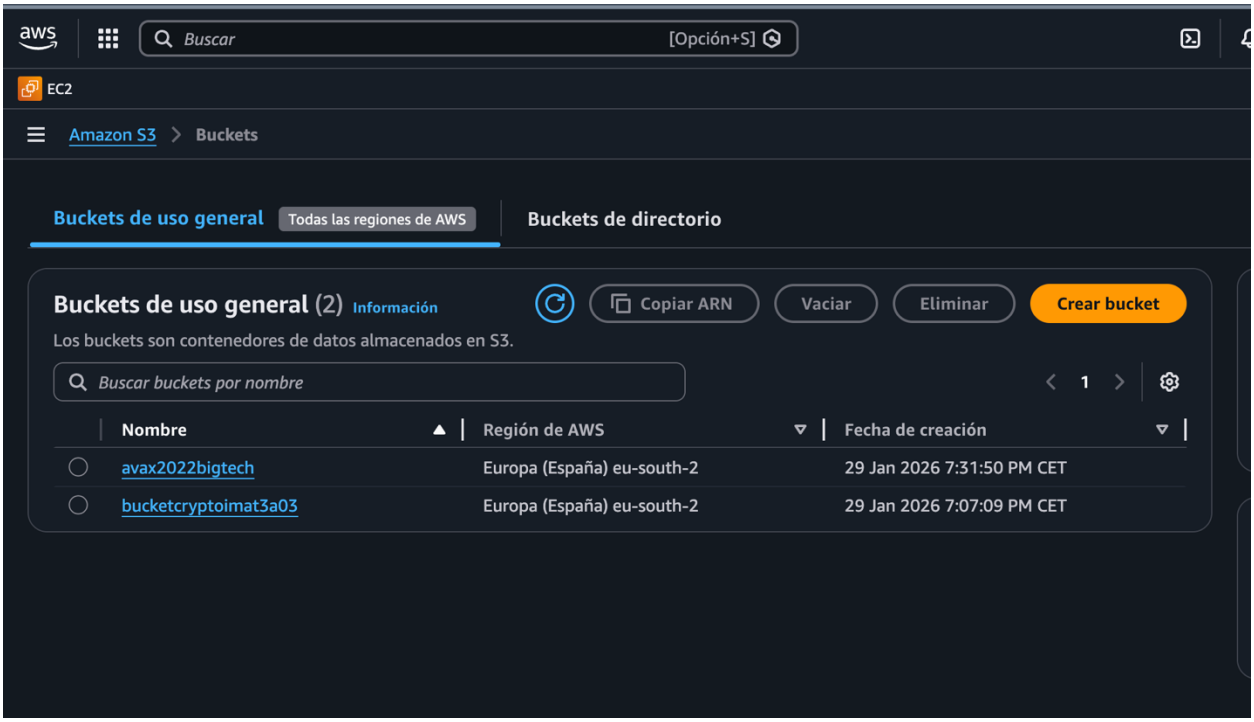

*Ilustración 2. Vista de la creación del bucket **bucketcryptoimat3a03** en Amazon S3*

Diseño de la solución

El diseño de la solución se ha planteado con el objetivo de ofrecer una arquitectura de almacenamiento sencilla, robusta y escalable, alineada con los principios de los data lakes en entornos cloud y con los requisitos del proyecto.
Dado que el análisis se centra en los datos históricos correspondientes a los últimos cuatro años, se decidió utilizar Amazon S3 como sistema de almacenamiento principal, aprovechando su durabilidad, escalabilidad y bajo coste. La arquitectura se basa en un único bucket de S3, dentro del cual los datos se organizan mediante una jerarquía de carpetas que permite una partición lógica y temporal de la información.
La decisión de utilizar un único bucket responde a varios criterios técnicos. En primer lugar, simplifica la gestión operativa, la asignación de permisos y la monitorización del almacenamiento. En segundo lugar, evita la fragmentación innecesaria de la información, manteniendo todos los datos históricos dentro de un mismo dominio. Por último, facilita la integración futura con servicios de análisis y procesamiento en batch como AWS Glue, que pueden trabajar de forma eficiente sobre estructuras bien definidas dentro de un mismo bucket.
La información se organiza siguiendo una estructura jerárquica basada en el activo, el año y el mes, adoptando el siguiente esquema:

```
crypto=avalanche/
  year=YYYY/
    month=MM/
      avax_YYYY_MM.csv
```

Esta partición temporal permite explotar de forma eficiente los datos en procesos posteriores, reduciendo el volumen de datos leídos y mejorando el rendimiento de las consultas. Además, esta estructura encaja de manera natural con la naturaleza secuencial de las series temporales financieras y con los casos de uso del proyecto, donde los análisis suelen centrarse en ventanas temporales concretas.
Desde el punto de vista de la ingesta, los datos históricos se obtienen desde TradingView utilizando una librería específica que permite descargar series temporales diarias AVAX/USD desde el exchange Binance. Posteriormente, se generan ficheros CSV mensuales que se almacenan temporalmente en el sistema de ficheros local y, a continuación, se cargan automáticamente en el bucket de Amazon S3.
Todo este proceso se ha automatizado mediante un script en Python, que se encarga de:

- Verificar la existencia previa del bucket y eliminarlo en caso necesario.
- Crear el bucket en la región especificada.
- Generar los ficheros CSV mensuales.
- Subir los archivos al bucket siguiendo la estructura definida.

Este diseño asegura que la solución sea genérica, reutilizable y fácilmente extensible, permitiendo incorporar nuevas criptomonedas o ampliar el histórico de datos en el futuro sin necesidad de modificar la arquitectura base.

avax_2022_03

datetime	symbol	open	high	low	close	volume
2022-03-01 01:00:00	Binance:AVAXUSD	84.6505157	90.8811261	83.5085987	86.9301438	223134.89
2022-03-02 01:00:00	Binance:AVAXUSD	86.8904315	89.9373406	82.4404475	83.4172211	130476.1200000001
2022-03-03 01:00:00	Binance:AVAXUSD	83.288821	84.3679137	77.2016415	78.5209468	185595.94000000024
2022-03-04 01:00:00	Binance:AVAXUSD	78.4512114	82.1774263	75.0133138	75.8056705	221516.52000000002
2022-03-05 01:00:00	Binance:AVAXUSD	75.8737297	78.6693755	73.450859	76.7053362	112290.87000000007
2022-03-06 01:00:00	Binance:AVAXUSD	76.6704283	77.0794982	72.1804669	72.5080433	94938.20000000007
2022-03-07 01:00:00	Binance:AVAXUSD	72.5727964	76.4690602	70.4452455	71.7407946	131298.1499999999
2022-03-08 01:00:00	Binance:AVAXUSD	71.763591	76.6195727	71.2411889	73.0405989	178900.59000000003
2022-03-09 01:00:00	Binance:AVAXUSD	73.0317467	80.5136634	72.3524588	77.6253032	220300.65999999986
2022-03-10 01:00:00	Binance:AVAXUSD	77.7039939	79.0229422	71.5636546	73.9542314	118308.55999999997
2022-03-11 01:00:00	Binance:AVAXUSD	73.9707706	77.0333944	70.8040176	71.2420557	244063.91000000003

*Ilustración 3. Datos mostrados en cada tabla de **avax_YYYY_MM.csv**, en este caso **avax_2022_03.csv***

Conclusión

En conclusión, durante este sprint se ha seguido un proceso completo que abarca desde la identificación de la necesidad de disponer de una base sólida de datos históricos para el análisis del mercado de criptomonedas hasta la implementación y validación de una primera capa de almacenamiento en la nube. A lo largo del desarrollo, se definió la estructura de almacenamiento más adecuada, se automatizó la creación y gestión del bucket en Amazon S3, se ingirieron los datos históricos correspondientes a los últimos cuatro años y se verificó inicialmente su calidad mediante un análisis exploratorio. Este enfoque permitió asegurar que los datos se almacenan de forma ordenada, consistente y preparada para su explotación posterior, sentando las bases técnicas del proyecto. Como principales logros, destaca el correcto funcionamiento de la solución implementada, la organización de los datos siguiendo buenas prácticas de data lake y la confirmación de que la información cargada es completa y fiable. Todo ello aporta un alto valor al proyecto, ya que garantiza que los siguientes sprints puedan centrarse en el procesamiento, análisis y visualización de los datos con la confianza de contar con una infraestructura de almacenamiento robusta, escalable y alineada con los objetivos del negocio.