Sprint 2

Grupo 03
Alejandro De Haro, Juan Díaz & Daniel Escobosa

Tecnologías de Procesamiento Big Data
3º Grado en Ingeniería Matemática e Inteligencia Artificial

Índice

Tabla de contenido

Introducción ***3***

Metodología ***4***

Conclusión ***7***

Introducción

Contexto

Este proyecto se desarrolla en el contexto de la creación de un nuevo departamento dentro de un gran banco, orientado al asesoramiento a clientes en el ámbito del trading de criptomonedas, un mercado caracterizado por su elevada volatilidad y por la necesidad de realizar análisis intensivos sobre grandes volúmenes de datos históricos y en tiempo real.

En este marco, el proyecto plantea el diseño de una arquitectura Big Data sobre Amazon Web Services (AWS) que permita no solo almacenar datos históricos de mercado, sino también catalogarlos, controlarlos y explotarlos de manera eficiente, escalable y segura. Tras una primera fase centrada en la ingesta y almacenamiento de datos en Amazon S3, este sprint amplía la arquitectura incorporando servicios específicos de gobierno del dato y consulta analítica, sentando las bases para una explotación avanzada de la información.

Este sprint constituye una etapa fundamental del proyecto, ya que aborda la implementación de la capa de metadatos y acceso a los datos, utilizando AWS Glue Data Catalog, AWS Glue Crawler y Amazon Athena. De este modo, se garantiza que los datos históricos almacenados puedan ser comprendidos, consultados y gestionados de forma estructurada, facilitando su reutilización en futuros casos de uso como el análisis de tendencias, la detección de patrones o la generación de informes analíticos.

Descripción del problema y objetivos del sprint

Antes de abordar tareas de análisis avanzado o procesamiento en tiempo real, es imprescindible asegurar que los datos históricos almacenados en el data lake se encuentran correctamente catalogados, gobernados y accesibles mediante herramientas estándar de consulta. El problema a resolver en este sprint consiste, por tanto, en dotar al sistema de una capa de gobierno del dato que permita gestionar los metadatos asociados a la información histórica almacenada en Amazon S3 y validar su explotación mediante consultas analíticas.

El objetivo principal de este sprint es implementar y automatizar el uso de AWS Glue para la catalogación de los datos históricos de mercado, tomando como caso de estudio la criptomoneda Avalanche (AVAX). Para ello, se plantean los siguientes objetivos específicos:

- Utilizar AWS Glue Data Catalog para centralizar los metadatos de los datos históricos almacenados en S3.
- Configurar y ejecutar un AWS Glue Crawler que permita detectar automáticamente esquemas, particiones y tablas.
- Automatizar la creación y ejecución del crawler mediante un script en Python.
- Validar la correcta catalogación de los datos mediante consultas SQL en Amazon Athena.
- Garantizar una estructura de metadatos coherente y alineada con las buenas prácticas de gobierno del dato.

Metodología

Entorno de desarrollo y ejecución

En esta historia de usuario se ha trabajado sobre la capa de gobierno del dato, utilizando los servicios administrados de AWS orientados a la catalogación, control de acceso y explotación analítica de los datos históricos almacenados previamente en Amazon S3.

El entorno de desarrollo se ha basado en Python, empleando el SDK oficial de AWS (boto3) para automatizar la interacción con AWS Glue. El objetivo principal ha sido evitar configuraciones manuales repetitivas y garantizar la idempotencia del proceso de catalogación de datos.

El script Spiderman.py se ha diseñado para ejecutarse bajo un rol IAM específico (SpidermanRol), que permite a AWS Glue acceder de forma controlada a los recursos necesarios: Amazon S3 y AWS Glue Data Catalog. Dicho rol se ha configurado siguiendo el principio de responsabilidad delegada, permitiendo que el servicio Glue actúe en nombre del usuario sin exponer credenciales.

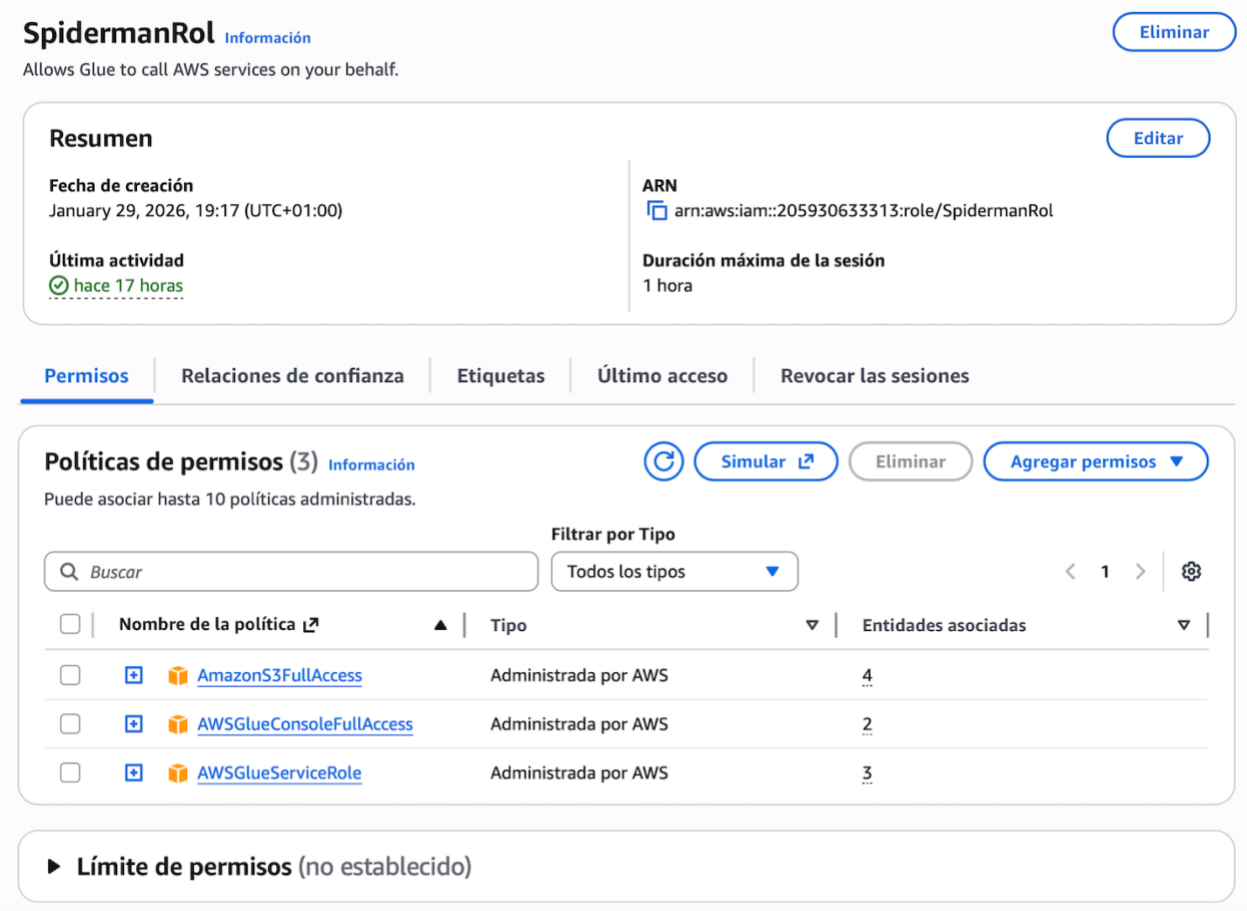

Ilustración 1. Vista de IAM

Automatización del AWS Glue Data Catalog

Para cumplir con los requisitos de la HU-3, se ha implementado un proceso completamente automatizado de creación y ejecución del AWS Glue Crawler, responsable de inspeccionar los datos almacenados en S3 y generar los metadatos correspondientes en el Glue Data Catalog.

El script Spiderman.py realiza las siguientes tareas:

1. **Verificación y creación de la base de datos del catálogo**
   Se comprueba si existe la base de datos trade_data_imat3a03.
   En caso de no existir, se crea automáticamente.
2. **Creación o actualización del crawler**
   El crawler Spiderman_PAPA se configura para apuntar al bucket: s3://bucketcryptoimat3a03/ y se asocia a la base de datos del catálogo indicada. Si el crawler ya existe, se actualiza para asegurar que su configuración es coherente con el estado actual del sistema.
3. **Ejecución y monitorización del crawler**
   El script inicia el crawler y monitoriza su estado hasta su finalización, informando del resultado del último crawl y posibles errores.

Este enfoque garantiza que el catálogo de datos esté siempre sincronizado con el contenido real del data lake en S3, facilitando el gobierno del dato y su posterior explotación analítica.

Catalogación y estructura de las tablas

Como resultado de la ejecución del crawler, AWS Glue genera automáticamente las tablas externas dentro del Glue Data Catalog.

Estas tablas reflejan la estructura de los ficheros CSV almacenados en S3, incluyendo:

- Columnas de series temporales financieras (datetime, open, high, low, close).
- Identificación del activo (por ejemplo, Binance:AVAXUSD).
- Particiones temporales que permiten una lectura eficiente de los datos.

Consulta y validación mediante Amazon Athena

Una vez catalogados los datos, se ha utilizado Amazon Athena como motor de consulta serverless para validar el correcto funcionamiento del gobierno del dato.

Athena permite ejecutar consultas SQL directamente sobre los datos almacenados en S3, apoyándose en los metadatos definidos en el Glue Data Catalog. Para la validación, se ha ejecutado un comando básico

Resultados de la consulta | Estado de la consulta

Completado | Tiempo en cola: 62 ms | Tiempo de ejecución: 1 sec | Datos analizados: 2.88 KB

Resultados (30) Copiar | Descargar resultados en formato CSV

Filas de búsqueda

#	datetime	symbol	open	high	low	close
1	2023-06-01 02:00:00	Binance:AVAXUSD	14.1145027	14.2974947	13.8612931	14.0968318
2	2023-06-02 02:00:00	Binance:AVAXUSD	14.1001635	14.5653236	13.9745597	14.4923211
3	2023-06-03 02:00:00	Binance:AVAXUSD	14.4951633	14.6022097	14.4078136	14.5764424
4	2023-06-04 02:00:00	Binance:AVAXUSD	14.5790367	14.9354181	14.5203035	14.7703829
5	2023-06-05 02:00:00	Binance:AVAXUSD	14.7760891	14.8774268	13.4827618	13.8623025
6	2023-06-06 02:00:00	Binance:AVAXUSD	13.8732164	14.6856719	13.8324572	14.6350741
7	2023-06-07 02:00:00	Binance:AVAXUSD	14.6337192	14.7200019	13.9614376	14.0217289
8	2023-06-08 02:00:00	Binance:AVAXUSD	14.0184139	14.1198188	13.7960809	13.929058
9	2023-06-09 02:00:00	Binance:AVAXUSD	13.9232358	14.247928	13.7141433	13.7596225

Ilustración 3. Resultados de la consulta

La ejecución de la consulta confirma que:

- Los metadatos han sido generados correctamente.
- El esquema de la tabla coincide con los datos reales.
- Los datos históricos pueden ser consultados de forma inmediata.

Contribución al gobierno del dato

La implementación de esta historia de usuario permite establecer una capa sólida de gobierno del dato sobre el data lake en S3, aportando los siguientes beneficios:

- Centralización de los metadatos mediante AWS Glue Data Catalog.
- Automatización del proceso de catalogación mediante scripts reproducibles.
- Control de accesos basado en roles IAM.
- Explotación analítica inmediata gracias a Amazon Athena.

Con esta solución, el proyecto dispone de una base robusta para futuras fases de análisis avanzado, procesamiento batch o integración con servicios analíticos adicionales, cumpliendo plenamente los objetivos definidos en la HU-3.

Conclusión

En conclusión, durante este sprint se ha abordado con éxito la implantación de la capa de gobierno del dato del proyecto, complementando la infraestructura de almacenamiento previamente definida. A lo largo del desarrollo, se ha diseñado y automatizado un proceso completo de catalogación de datos históricos mediante AWS Glue, asegurando que la información almacenada en Amazon S3 pueda ser interpretada y explotada de forma estructurada y eficiente. La creación y configuración de un rol IAM específico, junto con la automatización del AWS Glue Crawler mediante un script en Python, ha permitido garantizar un acceso controlado a los datos y una actualización consistente de los metadatos. Asimismo, la validación mediante Amazon Athena ha confirmado que los datos históricos pueden ser consultados correctamente, demostrando la coherencia entre el almacenamiento físico y el catálogo lógico de datos.