Sprint 5

Grupo 03
Alejandro De Haro, Juan Díaz & Daniel Escobosa

Tecnologías de Procesamiento Big Data
3º Grado en Ingeniería Matemática e Inteligencia Artificial

Índice

Tabla de contenido

Introducción.....3
Metodología.....4
Conclusión.....7

Introducción

Contexto

En los sprints anteriores se ha desarrollado una arquitectura Big Data orientada al procesamiento y análisis de datos de criptomonedas, abordando principalmente el tratamiento de información histórica. En este sprint, el proyecto evoluciona hacia un enfoque de procesamiento en tiempo real, incorporando flujos continuos de datos de cotización. Este cambio permite generar métricas actualizadas con baja latencia, lo cual es clave en entornos financieros.

Para ello, se implementa un sistema basado en Spark Structured Streaming capaz de consumir datos desde un tópico de entrada, procesarlos en ventanas temporales de cinco minutos y calcular el indicador VWAP (Volume Weighted Average Price). Los resultados se publican en un tópico de salida en formato JSON.

El VWAP es un indicador relevante en análisis financiero, ya que proporciona un precio medio ponderado por volumen, ofreciendo una visión más representativa del mercado que un promedio simple.

Descripción del problema y objetivos del sprint

El objetivo de este sprint es diseñar e implementar un sistema de procesamiento en streaming que permita calcular el VWAP en tiempo real a partir de cotizaciones de criptomonedas.

De forma más concreta, se persigue:

- Consumir datos en tiempo real desde un tópico de entrada.
- Procesarlos mediante Spark Structured Streaming.
- Agrupar los datos en ventanas de cinco minutos.
- Calcular el VWAP utilizando la fórmula: $\Sigma(\text{precio} \times \text{volumen}) / \Sigma(\text{volumen})$
- Generar resultados en formato JSON con la información de cada ventana.
- Publicar los resultados en un tópico de salida.

Este sprint introduce un enfoque de stream processing, ampliando las capacidades del sistema hacia el análisis en tiempo real.

Metodología

En este sprint se ha implementado un sistema de procesamiento en tiempo real orientado al cálculo del indicador VWAP a partir de datos de cotización de criptomonedas. Para ello, se ha utilizado Spark Structured Streaming en combinación con Apache Kafka, integrando así el flujo de datos desarrollado en el sprint anterior con una capa de procesamiento continuo.

Configuración del entorno

Para el desarrollo de esta práctica se ha utilizado AWS Glue como entorno de ejecución del job de Spark. Se ha creado un nuevo Glue Job específico para el procesamiento en streaming, al que se le ha asignado el rol personalizado SpidermanRol, el cual dispone de permisos S3 Full Access, suficientes para la gestión de checkpoints y almacenamiento temporal requerido por Spark.

Asimismo, se ha reutilizado la infraestructura de Kafka previamente configurada, manteniendo la autenticación mediante SASL_PLAINTEXT.

Ingesta de datos en tiempo real

El sistema parte del flujo de datos implementado en el sprint anterior, donde se capturan datos de mercado en tiempo real desde la API de Binance mediante WebSockets. Estos datos incluyen información relevante como símbolo, precio de cierre, volumen y timestamp.

Dichos datos son enviados a un topic de Kafka denominado imat3a-AVAX, que actúa como punto de entrada del sistema de streaming.

En este sprint, se ha actualizado el consumidor (kafka_real_time_consumer.py) para trabajar con el nuevo topic de salida imat3a-AVAX-VWAP, donde se publican los resultados procesados.

```
       _/m/'
Last login: Wed Mar 18 18:08:26 2026 from 18.101.90.50
[ec2-user@ip-172-31-20-180 ~]$ ls
binance_real_time.py  client.properties  kafka_2.13-3.9.2.tgz        kafka_simple_consumer.py
binance_to_kafka.py   kafka_2.13-3.9.2   kafka_real_time_consumer.py  kafka_simple_producer.py
[ec2-user@ip-172-31-20-180 ~]$ nano kafka_real_time_consumer.py
[ec2-user@ip-172-31-20-180 ~]$ python3 binance_to_kafka.py
Escuchando Binance para AVAXUSDT y publicando en imat3a-AVAX
Pulsa ENTER para salir...
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:46:59Z', 'close': 9.42, 'volume': 829.21, 'timestamp_ms': 1773942419999}
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:47:59Z', 'close': 9.42, 'volume': 44.78, 'timestamp_ms': 1773942479999}
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:48:59Z', 'close': 9.43, 'volume': 55.44, 'timestamp_ms': 1773942539999}
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:49:59Z', 'close': 9.43, 'volume': 106.34, 'timestamp_ms': 1773942599999}
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:50:59Z', 'close': 9.45, 'volume': 1043.73, 'timestamp_ms': 1773942659999}
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:51:59Z', 'close': 9.45, 'volume': 85.03, 'timestamp_ms': 1773942719999}
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:52:59Z', 'close': 9.48, 'volume': 1945.95, 'timestamp_ms': 1773942779999}
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:53:59Z', 'close': 9.46, 'volume': 1112.96, 'timestamp_ms': 1773942839999}
Enviando a Kafka...
key=AVAXUSDT value={'symbol': 'AVAXUSDT', '@timestamp': '2026-03-19T17:54:59Z', 'close': 9.47, 'volume': 1493.15, 'timestamp_ms': 1773942899999}
```

Ilustración 1. Mensajes en topic imat3a-AVAX

Procesamiento en streaming con Spark Structured Streaming

El núcleo de la solución se basa en el script vwap_streaming.py, que implementa el procesamiento en tiempo real mediante Spark Structured Streaming.

En primer lugar, se inicializa una sesión de Spark configurada para trabajar en modo streaming. A continuación, se establece la conexión con Kafka como fuente de datos, suscribiéndose al topic de entrada imat3a-AVAX.

Los mensajes consumidos, originalmente en formato binario, son transformados a JSON y posteriormente parseados utilizando un esquema predefinido que permite estructurar los datos en columnas (símbolo, precio, volumen, timestamp, etc.). Este paso es fundamental para poder operar sobre los datos de forma estructurada dentro de Spark.

Cálculo del indicador VWAP

Una vez estructurados los datos, se procede al cálculo del indicador VWAP. Para ello, se realiza una agregación en ventanas temporales de cinco minutos, agrupando los datos por símbolo de criptomoneda.

El cálculo se basa en la fórmula: $VWAP = \Sigma(\text{precio} \times \text{volumen}) / \Sigma(\text{volumen})$

Además, se ha incorporado el uso de watermarks para gestionar posibles retrasos en la llegada de datos, mejorando la robustez del sistema frente a eventos fuera de orden.

El resultado de esta agregación es un conjunto de registros que contienen el intervalo temporal (inicio y fin de ventana), el símbolo de la criptomoneda y el valor calculado del VWAP.

Formateo y publicación de resultados

Una vez calculado el VWAP, los datos son formateados para cumplir con el formato requerido, generando una estructura JSON que incluye:

- window_start
- window_end
- symbol
- vwap

Posteriormente, estos resultados son enviados a Kafka utilizando un nuevo topic de salida denominado imat3a-AVAX-VWAP, donde la clave corresponde al símbolo de la criptomoneda y el valor contiene el JSON completo.

Para garantizar la tolerancia a fallos y la consistencia del procesamiento, se ha configurado un checkpoint en el sistema de archivos.

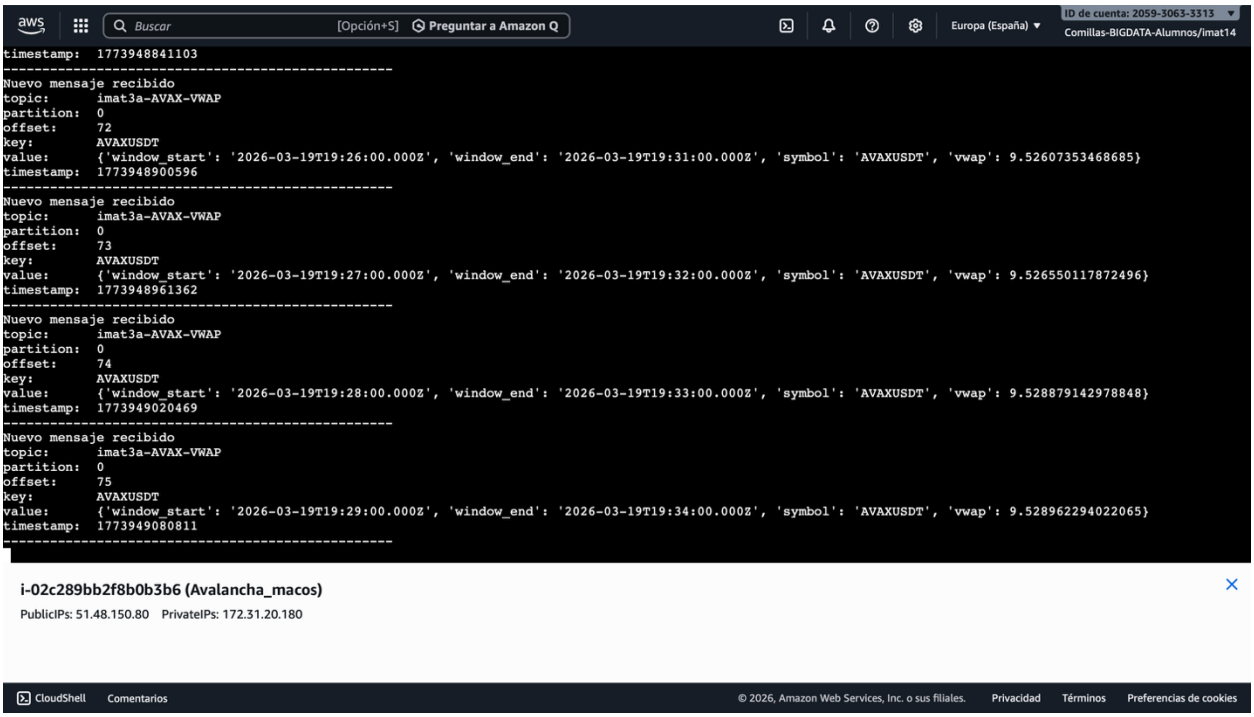

Ilustración 2. Mensajes en topic imat3a-AVAX-VWAP

Conclusión

En este sprint se ha abordado el procesamiento de datos en tiempo real dentro de la arquitectura Big Data desarrollada previamente, dando un paso más allá en el tratamiento de flujos continuos de información. Tras la incorporación de Apache Kafka en el sprint anterior para la ingestión de datos en streaming, en esta fase se ha centrado el trabajo en su procesamiento y análisis en tiempo real.

Para ello, se ha implementado un sistema basado en Spark Structured Streaming, capaz de consumir datos de cotización de criptomonedas desde un tópico de entrada en Kafka, procesarlos mediante ventanas temporales y generar información agregada de valor. En concreto, se ha desarrollado el cálculo del indicador VWAP (Volume Weighted Average Price) para ventanas de cinco minutos, permitiendo obtener una medida representativa del precio de mercado ponderado por volumen.

Los resultados generados se publican en un tópico de salida en formato JSON, lo que facilita su consumo por otros sistemas o su integración en futuras capas analíticas o de visualización. Este enfoque refuerza la arquitectura distribuida del sistema, manteniendo el desacoplamiento entre productores, procesadores y consumidores de datos.

En conjunto, este sprint consolida la transición hacia una arquitectura completa de procesamiento en streaming, en la que no solo se capturan eventos en tiempo real, sino que también se transforman y analizan de forma continua. La integración de Spark Structured Streaming permite construir soluciones escalables y eficientes, capaces de generar indicadores clave en tiempo real, lo cual resulta especialmente relevante en entornos como el análisis de mercados financieros.